



**Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»**

**Отчет по рубежному контролю №1
«Технологии разведочного анализа и обработки данных»
по дисциплине «Технологии машинного обучения»
Вариант №30**

Выполнил:
студент группы ИУ5Ц-83Б
Рабинович А.Д.
подпись, дата

Проверил:
к.т.н., доц., Гапанюк Ю.Е.
подпись, дата

2026 г.

СОДЕРЖАНИЕ ОТЧЕТА

1. Примечание	3
2. Дополнительные требования по группам	3
3. Листинг	4
3.1. Подключение библиотеки и импорт данных	4
3.2. Импорт данных	4
3.3. Изучение данных	5
3.4. Пропуски	6
3.5. Создание пропусков (по условию задания)	6
3.6. Удаление строк с пропусками	7
3.7. Анализ выбросов (Ящик с усами) — ДОПОЛНИТЕЛЬНОЕ ТРЕБОВАНИЕ	7
3.8. Гистограмма (распределение CGPA)	8
3.9. Диаграмма рассеяния (GRE Score vs Chance of Admit)	9
3.10. Корреляционная тепловая карта	10
3.11. Выводы по EDA	11
4. Заключение	12

1. Примечание

В заданном наборе данных Admission_Predict_Ver1.1.csv изначально отсутствовали пропуски и категориальные признаки, поэтому в соответствии с условием задания они были созданы искусственно:

Категориальный признак Research (опыт исследований) был преобразован из числового в строковый для демонстрации методов кодирования (Label Encoding и One-Hot Encoding)

Пропуски (15% значений) были созданы в количественном признаке GRE Score и порядковом категориальном признаке University Rating

2. Дополнительные требования по группам

Согласно заданию, для студентов группы ИУ5Ц-83Б:

"...для произвольной колонки данных построить график "Ящик с усами (boxplot)"

В рамках Задачи №4 (Разведочный анализ данных) был построен boxplot для оценки зависимости среднего балла CGPA от шанса поступления Chance of Admit.

Задача №4

Для заданного набора данных постройте основные графики, входящие в этап разведочного анализа данных. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Какие графики Вы построили и почему? Какие выводы о наборе данных Вы можете сделать на основании построенных графиков?

Наборы данных:

<https://www.kaggle.com/mohansacharya/graduate-admissions> (файл Admission_Predict_Ver1.1.csv)

3. Листинг

3.1. Подключение библиотеки и импорт данных

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Настройка стиля графиков
sns.set_style("whitegrid")
plt.rcParams['figure.figsize'] = (10, 6)

print("Библиотеки успешно загружены")
```

Библиотеки успешно загружены

3.2. Импорт данных

```
# Загрузка данных (используем Ver1.1)
df = pd.read_csv('Admission_Predict_Ver1.1.csv')

# Очистка названий столбцов: убираем лишние пробелы
df.columns = df.columns.str.strip()

print("=" * 50)
print("ИНФОРМАЦИЯ О ДАТАСЕТЕ")
print("=" * 50)
print(f"Размер датасета: {df.shape}")
print(f"Названия столбцов: {list(df.columns)}")
print(f"\nПервые 5 строк:")
df.head()
```

```
=====
ИНФОРМАЦИЯ О ДАТАСЕТЕ
=====
```

Размер датасета: (500, 9)

Названия столбцов: ['Serial No.', 'GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR', 'CGPA', 'Research', 'Chance of Admit']

3.3. Изучение данных

```
# Информация о типах данных и пропусках
print("\n" + "=" * 50)
print("ИНФОРМАЦИЯ О КОЛОНКАХ")
print("=" * 50)
df.info()
```

```
=====
ИНФОРМАЦИЯ О КОЛОНКАХ
=====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Serial No.            500 non-null   int64
1   GRE Score              500 non-null   int64
2   TOEFL Score            500 non-null   int64
3   University Rating      500 non-null   int64
4   SOP                    500 non-null   float64
5   LOR                    500 non-null   float64
6   CGPA                   500 non-null   float64
7   Research                500 non-null   int64
8   Chance of Admit        500 non-null   float64
dtypes: float64(4), int64(5)
memory usage: 35.3 KB
```

```
# Статистическое описание
print("\n" + "=" * 50)
print("ОПИСАТЕЛЬНАЯ СТАТИСТИКА")
print("=" * 50)
df.describe()
```

```
=====
ОПИСАТЕЛЬНАЯ СТАТИСТИКА
=====
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
count	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000
mean	250.500000	316.472000	107.192000	3.114000	3.374000	3.48400	8.576440	0.560000	0.72174
std	144.481833	11.295148	6.081868	1.143512	0.991004	0.92545	0.604813	0.496884	0.14114
min	1.000000	290.000000	92.000000	1.000000	1.000000	1.00000	6.800000	0.000000	0.34000
25%	125.750000	308.000000	103.000000	2.000000	2.500000	3.00000	8.127500	0.000000	0.63000
50%	250.500000	317.000000	107.000000	3.000000	3.500000	3.50000	8.560000	1.000000	0.72000
75%	375.250000	325.000000	112.000000	4.000000	4.000000	4.00000	9.040000	1.000000	0.82000
max	500.000000	340.000000	120.000000	5.000000	5.000000	5.00000	9.920000	1.000000	0.97000

Первичные выводы:



- Датасет содержит 400 записей и 9 колонок.
- Пропуски в данных отсутствуют (400 non-null значений).
- Целевой признак: `Chance of Admit` (вероятность поступления от 0 до 1).
- Все признаки являются числовыми.

Анализ описательной статистики

- GRE Score: Среднее ≈ 317 баллов. Минимум 290, максимум 340.
- TOEFL Score: Среднее ≈ 107 баллов. Диапазон от 92 до 120.
- University Rating: Среднее ≈ 3.09 . Значения от 1 до 5.
- CGPA: Среднее ≈ 8.60 . Минимум 6.8, максимум 9.92.
- Research: $\approx 54.8\%$ студентов имеют опыт исследований.
- Chance of Admit: Вероятность поступления от 0.34 до 0.97, среднее ≈ 0.724 .

3.4. Пропуски

Столбец	Количество пропусков
Serial No	0
GRE Score	0
TOEFL Score	0
University Rating	0
SOP	0
LOR	0
CGPA	0
Research	0
Chance of Admit	0

Пропуски в исходных данных отсутствуют.

3.5. Создание пропусков (по условию задания)

```
np.random.seed(42)
df_with_nulls = df.copy()

# Создание пропусков в GRE Score
mask_gre = np.random.random(len(df_with_nulls)) < 0.15
df_with_nulls.loc[mask_gre, 'GRE Score'] = np.nan

# Создание пропусков в University Rating
mask_rating = np.random.random(len(df_with_nulls)) < 0.15
df_with_nulls.loc[mask_rating, 'University Rating'] = np.nan

print("Пропусков в 'GRE Score':", df_with_nulls['GRE Score'].isnull().sum())
print("Пропусков в 'University Rating':", df_with_nulls['University Rating'].isnull().sum())
print("\nОбщее количество строк с пропусками:", df_with_nulls.isnull().any(axis=1).sum())
```

Пропусков в 'GRE Score': 89

Пропусков в 'University Rating': 77

Общее количество строк с пропусками: 150

Результат:

Пропусков в 'GRE Score': 89

Пропусков в 'University Rating': 77

Общее количество строк с пропусками: 150

3.6. Удаление строк с пропусками

```
df_clean = df_with_nulls.dropna()

print(f"Размер исходного датасета (с пропусками): {df_with_nulls.shape}")
print(f"Размер датасета после удаления пропусков: {df_clean.shape}")
print(f"Удалено строк: {df_with_nulls.shape[0] - df_clean.shape[0]}")
```

Размер исходного датасета (с пропусками): (500, 9)

Размер датасета после удаления пропусков: (350, 9)

Удалено строк: 150

Результат:

Размер исходного датасета (с пропусками): (500, 9)

Размер датасета после удаления пропусков: (350, 9)

Удалено строк: 150

3.7. Анализ выбросов (Ящик с усами) — ДОПОЛНИТЕЛЬНОЕ ТРЕБОВАНИЕ

```
# Проверим наличие столбца
print("Доступные столбцы:", df_clean.columns.tolist())

target_col = 'Chance of Admit'

# Создадим копию для безопасного добавления колонки
df_boxplot = df_clean.copy()

# Создадим категориальную версию целевого признака для наглядности
df_boxplot['Admit_Category'] = pd.cut(df_boxplot[target_col],
                                     bins=[0, 0.5, 0.7, 0.8, 1.0],
                                     labels=['<0.5 (Низкий)', '0.5-0.7 (Средний)', '0.7-0.8 (Хороший)', '>0.8 (Высокий)'])

plt.figure(figsize=(12, 6))
sns.boxplot(x='Admit_Category', y='CGPA', data=df_boxplot, palette='Set2')
plt.title('Зависимость среднего балла (CGPA) от шанса поступления (Boxplot)', fontsize=14, fontweight='bold')
plt.xlabel('Категория шанса поступления')
plt.ylabel('CGPA (средний балл)')
plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```

Доступные столбцы: ['Serial No.', 'GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR', 'CGPA', 'Research', 'Chance of Admit']




Рисунок 1 — Ящик с усами (Boxplot): зависимость CGPA от шанса поступления

Вывод: Медиана CGPA значительно выше для студентов с высоким шансом поступления (>0.8). Выбросы практически отсутствуют. Это подтверждает ключевую роль среднего балла в поступлении.

3.8. Гистограмма (распределение CGPA)

```
plt.figure(figsize=(10, 6))
sns.histplot(df_clean['CGPA'], bins=15, kde=True, color='skyblue', edgecolor='black')
plt.title('Распределение среднего балла (CGPA)', fontsize=14, fontweight='bold')
plt.xlabel('CGPA (средний балл)')
plt.ylabel('Частота')
plt.axvline(df_clean['CGPA'].mean(), color='red', linestyle='--', label=f'Среднее: {df_clean["CGPA"].mean():.2f}')
plt.legend()
plt.tight_layout()
plt.show()
```





Рисунок 2 — Гистограмма распределения среднего балла (CGPA)

Вывод: Распределение CGPA близко к нормальному. Большинство студентов имеют баллы в диапазоне от 8.5 до 9.5, что логично для кандидатов в магистратуру.

3.9. Диаграмма рассеяния (GRE Score vs Chance of Admit)

```
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df_clean, x='GRE Score', y=target_col, hue='Research', size='Research',
               sizes={0: 50, 1: 100}, alpha=0.7, palette='Set1')
plt.title('Влияние баллов GRE на шанс поступления', fontsize=14, fontweight='bold')
plt.xlabel('GRE Score')
plt.ylabel('Chance of Admit (вероятность поступления)')
plt.legend(title='Research Experience', loc='lower right')
plt.tight_layout()
plt.show()
```



Рисунок 3 — Диаграмма рассеяния: зависимость шанса поступления от баллов GRE

Вывод: Наблюдается сильная положительная корреляция: чем выше баллы GRE, тем выше шанс на поступление. Студенты с опытом исследований (Research=1) имеют более высокий шанс.

3.10. Корреляционная тепловая карта

```
# Вычисление корреляционной матрицы
corr_columns = ['GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR', 'CGPA', 'Research', target_col]
corr_matrix = df_clean[corr_columns].corr()

plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5, square=True,
            cbar_kws={"shrink": 0.8, "label": "Коэффициент корреляции"})
plt.title('Корреляционная матрица признаков', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```




Рисунок 4 — Корреляционная тепловая карта признаков

Выводы:

CGPA (0.87) и GRE Score (0.81) имеют очень сильную положительную корреляцию с целевым признаком

Research (0.38) и University Rating (0.42) имеют умеренную корреляцию

Сильных корреляций между признаками (мультиколлинеарности) не обнаружено

3.11. Выводы по EDA

На основании проведенного разведочного анализа можно сделать следующие выводы:

1. ДАННЫЕ КАЧЕСТВЕННЫЕ И ПРЕДСКАЗУЕМЫЕ:

- Распределения признаков (CGPA, GRE Score, TOEFL Score) близки к нормальным

- Взаимосвязи между признаками и целевой переменной интуитивно понятны

2. КЛЮЧЕВЫЕ ФАКТОРЫ ПОСТУПЛЕНИЯ:

- CGPA (средний балл) — коэффициент корреляции 0.87
- GRE Score — коэффициент корреляции 0.81
- Опыт исследований (Research) также важен, но в меньшей степени (0.38)

3. ОТСУТСТВИЕ ПРОБЛЕМ В ДАННЫХ:

- После удаления строк с пропусками в данных нет явных аномалий или выбросов

- Мультиколлинеарность между признаками находится на приемлемом уровне

4. ПРИГОДНОСТЬ ДЛЯ МАШИННОГО ОБУЧЕНИЯ:

- Данные отлично подходят для решения задачи РЕГРЕССИИ
- Высокие корреляции с целевой переменной позволяют строить точные прогнозы

- Рекомендуемые модели: линейная регрессия, градиентный бустинг, случайный лес

4. Заключение

В ходе выполнения рубежного контроля №1 (вариант 30) были успешно решены все поставленные задачи:

1. Загрузка и первичный анализ — выполнены, данные изучены
2. Создание и обработка пропусков — искусственно созданы 15% пропусков и удалены строки с ними
3. Построение графиков EDA — выполнены все необходимые визуализации, включая обязательный для группы ИУ5Ц-83Б boxplot
4. Формулирование выводов — сделаны обоснованные выводы о качестве данных и их пригодности для машинного обучения

Все этапы работы были реализованы в среде Jupyter Notebook с использованием библиотек pandas, numpy, matplotlib, seaborn и sklearn.